


Introduzione al corso di Visione Artificiale e Riconoscimento

Annalisa Franco
annalisa.franco@unibo.it



Cos'è la Visione Artificiale?

La **Visione Artificiale** è una disciplina molto ampia che studia gli aspetti connessi allo studio e alla progettazione di **sistemi artificiali** in grado di eseguire compiti **visivi e percettivi** tipici dell'uomo.



Visione Artificiale


Acquisizione di immagini




Elaborazione di immagini




Ricostruzione 3D



Comprensione della scena



Riconoscimento di pattern



Localizzazione di oggetti



Detection del movimento
e tracking di oggetti

Pattern recognition

Il **Pattern recognition** è una delle più importanti “sotto-discipline” della VA.

Cos'è un pattern?

Watanabe definisce un pattern come **l'opposto del caos** e come un'entità vagamente definita cui può essere dato un nome.



Riconoscimento e classificazione

- ❑ Nel contesto del pattern recognition il **riconoscimento** è inteso come **classificazione** o **categorizzazione** ovvero l'assegnamento del pattern a una **classe**.
- ❑ Per **classe** intendiamo **un insieme di entità aventi proprietà comuni** (ad. esempio i diversi modi in cui le persone scrivono il carattere "A"). Il concetto di classe è **semantico** e dipende strettamente dall'applicazione:
 - ❑ *La classe dipende dall'obiettivo dell'applicazione: riconoscere una lettera richiede 21 classi; distinguere alfabeti diversi può richiederne soltanto 2.*
- ❑ Le classi possono essere **definite** dal progettista (classificazione supervisionata) o **"imparate"** autonomamente dal sistema (classificazione non supervisionata).






- La visione artificiale e il pattern recognition stanno acquistando un ruolo sempre **più rilevante** nella nostra società;
- In molteplici ambiti si presenta la necessità di **supportare l'essere umano** con tecniche automatiche di analisi di dati e immagini;
- Sono **pochi i professionisti** in grado di utilizzare consapevolmente le tecnologie esistenti o di progettare soluzioni innovative.

Perché è così difficile?




Perché è così difficile?



Human and Mechanical PR


Riconoscimento umano

- Classifica pattern in modo rapido e intuitivo.
- Il mapping tra stimolo e decisione è opaco.
- I dettagli del processo non sono osservabili, spesso nemmeno dal soggetto.



Riconoscimento automatico

- Richiede un mapping esplicito e trasparente.
- Il processo deve essere descritto formalmente.
- La classificazione diventa un algoritmo implementabile.




Progetto di applicazioni di VA (teoria)

- Dare una **descrizione appropriata degli oggetti**, fisici o concettuali, in termini di **caratteristiche (features)**, appartenenti a uno **spazio di rappresentazione**.
- Specificare uno **spazio di interpretazione** (lo spazio delle **classi**)
- Fornire un **mapping** fra lo spazio di rappresentazione e quello di interpretazione.
- Determinare un **operatore (algoritmo)** che esegua questo mapping, ovvero che esegua la **classificazione**.



$$\rightarrow \mathbf{x} = [x_1, x_2, \dots, x_n]$$



feature $\mathbf{x}$ $\longrightarrow$ cane
?
gatto

Progetto di applicazioni di VA (pratica)

- Perdere giorni nel tentativo di far funzionare telecamere, frame grabber e altri sensori...
- ... oppure trovare dataset rappresentativi e di dimensione adeguata.
- Cercare in letteratura quali approcci sono stati utilizzati con successo per la soluzione dello stesso problema (o di un problema analogo).
- Partire da codice sviluppato da altri, adattandolo se possibile alle nostre esigenze.



Anche un tale approccio PRATICO richiede esperienza

Per risolvere in modo ottimale ogni problema specifico è necessario un metodo ad hoc !!!

Stato dell'arte: alcuni esempi



Face detection



Face recognition



Automotive



Healthcare



Realtà
aumentata



3D modeling




Video-based
interaction



Riconoscimento
oggetti

3D modeling




- Tecniche di **fotogrammetria**, **Structure from Motion (SfM)** e **Multi-View Stereo (MVS)** permettono di ricostruire modelli 3D di edifici e ambienti urbani a partire da immagini acquisite da differenti punti di vista.
- Una delle applicazioni più note è la realizzazione di **mappe 3D fotorealistiche**, come quelle utilizzate nei servizi di mapping.

Video-based interaction / gaming



- La Visione Artificiale consente di interpretare **movimenti, gesti, postura ed espressioni dell'utente**, permettendo un'interazione naturale con sistemi digitali senza dispositivi di input tradizionali.
- Queste tecnologie sono utilizzate in **gaming, realtà aumentata/virtuale, gesture control e interfacce contactless**, dove il corpo stesso diventa uno strumento di comando.

Automotive




- La Visione Artificiale permette al veicolo di **percepire e interpretare l'ambiente circostante**, costituendo una tecnologia fondamentale per i sistemi **ADAS** (Advanced Driver Assistance System) e la **guida autonoma**.
- Telecamere e algoritmi di visione vengono utilizzati per **rilevare veicoli, pedoni e ciclisti, riconoscere segnali stradali e semafori, individuare le corsie, stimare distanze e ostacoli** e comprendere la scena stradale.
- La visione viene inoltre utilizzata **all'interno dell'abitacolo** per il *Driver Monitoring*, ad esempio per riconoscere **distrazione, sonnolenza, direzione dello sguardo e postura del conducente**, e per monitorare gli occupanti.

Ambient Assisted Living



- La Visione Artificiale può supportare persone anziane o fragili nel vivere in modo più **autonomo e sicuro**, monitorando attività e situazioni di rischio all'interno dell'ambiente domestico.
- Telecamere e sensori visivi possono riconoscere **cadute, posture anomale, inattività prolungata, comportamenti quotidiani e condizioni potenzialmente pericolose**, attivando assistenza quando necessario.

Supermercati/acquisti




- Il riconoscimento dei prodotti alimentari è fondamentale per i sistemi di **self-checkout** e per la **gestione dell'inventario**.
- I sistemi basati sulla **visione artificiale** rilevano e identificano i prodotti in tempo reale, consentendo un checkout più rapido, contactless e intuitivo.
- **Sistemi commerciali:**
 - **Amazon Just Walk Out:** telecamere + **sensori di peso** + AI per un'esperienza di acquisto completamente **senza checkout**.
 - **Trigo, Zippin:** sistemi di visione con telecamere installate a soffitto, eventualmente integrati con **sensori di peso**.
 - **Mashgin:** telecamere multi-angolo per il riconoscimento ultra-rapido dei prodotti, **senza codici a barre né sensori aggiuntivi**.

Simultaneous Localization and Mapping (SLAM)



- La Visione Artificiale consente a un robot o a un veicolo di **costruire una mappa dell'ambiente mentre stima contemporaneamente la propria posizione al suo interno.**
- Nel **Visual SLAM**, le immagini acquisite da una o più telecamere vengono utilizzate per individuare e seguire punti della scena, stimare il movimento della camera e ricostruire progressivamente la struttura dell'ambiente.

Realtà aumentata



- È possibile **integrare informazioni e oggetti virtuali con il mondo reale**, stimando in tempo reale la posizione e l'orientamento della camera e comprendendo la geometria dell'ambiente.
- Gli elementi digitali possono così essere **ancorati alla scena reale** e mantenere una posizione coerente mentre l'utente si muove.
- Gaming, interior design, navigazione, manutenzione industriale, visualizzazione di prodotti.


Applicazioni in ambito industriale



Ispezione visuale



Calibrazione



Rilevamento difetti




Conteggio e misurazione



SLAM

Face detection



Disgust



Surprise



Sad



Angry




Fear



Happy




Contempt




Neutral

Riconoscimento biometrico

Il termine **riconoscimento biometrico** fa riferimento all'uso di caratteristiche *fisiologiche* o *comportamentali* distintive per l'identificazione umana.



FISIOLOGICHE



COMPORTAMENTALI

Una **grandezza biometrica** è descritta come una caratteristica che possa essere misurata e successivamente identificata al fine di attestare l'identità di una persona.




Il sistema di Bertillon

Introdotta nel 1882, proponeva la misurazione di caratteristiche antropometriche per schedare i criminali. Richiedeva di fotografare il soggetto e di misurare 9-10 caratteristiche




Il caso dei fratelli West

Will West, condannato per un reato minore nel 1903, all'arrivo in un penitenziario del Kansas, fu informato che era già in prigione, condannato all'ergastolo per un omicidio di primo grado.



Principali problematiche



Bassa resistenza agli attacchi




The magic passport




Abstract - *once upon a time there was a criminal; he was reading his e-mail when a banner caught his attention: low cost flights for the destination of his dreams! He had already started to book the trip when suddenly realized that, being wanted by the police, he could not use his passport without being arrested. What to do? He could not miss that opportunity, so he called a good friend and they started to think for a possible solution. Do you want to know if they succeeded? Read the rest of the paper and find it out...*

Quattro approcci al Pattern Recognition




1 Template matching

confronto con prototipi



2 Statistico

features + distribuzioni



3 Strutturale / sintattico


parti + relazioni



4 Neurale deep learning

rappresentazioni apprese

Template matching



Come funziona

- Si memorizzano uno o più template per ciascuna classe.
- Il pattern in ingresso viene confrontato direttamente con i template.
- La decisione dipende da una misura di similarità o distanza.
- È semplice e intuitivo, ma sensibile a scala, rotazione, rumore e deformazioni.

$$\text{classe} = \arg \min d(x, T_k)$$


Approccio diretto: confronto fra immagine osservata e prototipi noti.

Template matching


Immagine in ingresso
(pattern osservato)




Template di riferimento (da un'altra persona)



Migliore corrispondenza
(posizione del template nell'immagine)



Approccio statistico



Come funziona


- Ogni oggetto è descritto da un vettore di caratteristiche numeriche.
- Le classi sono modellate come regioni o distribuzioni nello spazio delle features.
- La classificazione usa distanze, probabilità o superfici di decisione.
- Funziona bene quando le features separano chiaramente le classi.

$$\mathbf{x} = [x_1, x_2, \dots, x_n] \rightarrow C_i$$

Il problema diventa geometrico/probabilistico nello spazio delle caratteristiche.

Approccio statistico

Estrazione delle caratteristiche



Di ogni oggetto viene misurata l'estensione dei pixel rispetto al baricentro (primo momento invariante)

Classificazione


Se E è l'estensione dell'oggetto da classificare in una delle 2 classi T (oggetti allungati a forma di T) e C (oggetti più circolari):

$$\text{l'oggetto è di classe } \begin{cases} T & \text{se } (E - AvgT)^2 \leq (E - AvgC)^2 \\ C & \text{altrimenti} \end{cases}$$

classificatore di minima distanza euclidea

dove $AvgT$ ed $AvgC$ sono le estensioni medie degli oggetti delle 2 classi T e C misurate su di un set di addestramento.

Approccio strutturale / sintattico



Come funziona


- Il pattern è composto da primitive: linee, archi, punti, regioni, parti.
- Conta non solo la presenza delle parti, ma anche la loro organizzazione.
- La classe può essere descritta da grafi, grammatiche o regole strutturali.
- È utile per oggetti con struttura riconoscibile e relazioni spaziali forti.

pattern = primitive + relazioni


Riconoscere significa interpretare la struttura interna del pattern.

Approccio strutturale




Es. classificazione di impronte digitali





Calcolo Immagine
Direzionale



Segmentazione
Immagine
Direzionale



Inexact Graph
Matching



Costruzione grafo
Relazionale

Approccio neurale / deep learning



Come funziona

- Il modello apprende rappresentazioni progressive dai dati di training.
- Le reti convoluzionali combinano estrazione di features e classificazione.
- Richiede molti dati, potenza di calcolo e validazione accurata.
- È oggi dominante in molti compiti di visione artificiale.

immagine → features apprese → classe


Il mapping viene appreso ottimizzando il modello sui dati

Programma del corso (1)

Richiami di elaborazione di immagini e filtraggio digitale

Estrazione di feature

- Handcrafted features vs Representation learning
- Tecniche di segmentazione (basso livello) basate su analisi del colore, algoritmo Mean Shift;
- Feature di colore, tessitura e forma



Programma del corso (2)




Image stitching e registrazione immagini 2D

- Keypoint e descrittori locali
- Algoritmo Ransac per feature matching.
- Cenni ad applicazioni in ambito robotico: SLAM

Segmentazione semantica in immagini

Tecniche di segmentazione basate su deep learning con esempi applicativi



Programma del corso (3)

Riconoscimento “in the wild”

- Sistemi content-based image retrieval;
- Bag of visual Words;
- Tecniche di localizzazione/riconoscimento di oggetti tramite template matching;
- Trasformata di Hough;
- Tecniche di deep learning per la localizzazione/riconoscimento di oggetti.



Analisi video

- Tecniche di base per background subtraction e modeling, rilevazione del movimento
- Cenni a tecniche di analisi video
- Tecniche di deep learning per analisi video.

Informazioni generali

- Metodi didattici
 - **Lezioni frontali** dedicate agli aspetti teorici e metodologici della computer vision, affiancate da **esercitazioni guidate** in laboratorio, individuali o di gruppo.
 - Durante le esercitazioni gli studenti sviluppano applicazioni di visione artificiale utilizzando **librerie open source** multiplatforma (OpenCV) per computer vision e **framework di Deep Learning** (es. Tensorflow, PyTorch).
 - Il materiale didattico comprende **slide** e **dispense** del docente, **codice sorgente**, **progetto scheletro** per le esercitazioni e ulteriore materiale reso disponibile sulla piattaforma Virtuale.
- Modalità d'esame
 - Consegna e discussione di un elaborato concordato con il docente
 - Prova teorica (colloquio orale) sugli argomenti visti a lezione.
 - **Il progetto costituisce la base della valutazione**
 - **La prova orale può modificare il punteggio ottenuto sul progetto, indicativamente fino a ± 3 punti**

Il progetto di V&R

- **Obiettivo:** affrontare un problema di visione con tecniche classiche e/o approcci basati su deep learning.
- **Svolgimento:** l'elaborato può essere svolto singolarmente o in gruppo (max 3 persone).
- **Valutazione sperimentale:** lo sviluppo del progetto deve includere una validazione sperimentale appropriata degli algoritmi sviluppati:
 - Corretta suddivisione tra **training, validation e test set**;
 - analisi approfondita delle **prestazioni**, adottando **indicatori** opportuni per il tipo di problema affrontato;
 - analisi delle principali **cause d'errore**.
 - se possibile, **confronto con altri metodi** allo stato dell'arte (già testati sullo stesso dataset)

Il progetto di V&R

- **Complessità:** la complessità del progetto deve essere rapportata al numero di crediti erogati dal corso

6 CFU $\approx$ **150 ore di impegno complessivo**

lezioni + preparazione elaborato + studio della teoria

- È fondamentale che **concordiate il progetto con i docenti** prima di iniziare a lavorarci.

Dataset: non sempre è facile trovare un dataset per il problema che si desidera affrontare... la prima verifica da fare è proprio questa (a meno che non vogliate acquisire voi i dati).



La relazione

- 1** Introduzione al problema
- 2** Stato dell'arte
- 3** Approccio sviluppato
- 4** Valutazione sperimentale
- 5** Conclusioni e sviluppi futuri

Elementi di valutazione

- **Soluzione proposta** (originalità, validità dal punto di vista tecnico);
- Capacità di **analisi** critica dei risultati;
- **Correttezza** del protocollo di valutazione utilizzato;
- **Autonomia** nella realizzazione dell'elaborato;
- Raggiungimento di un livello di **prestazioni** accettabile.

L'esame è su appuntamento, non ci sono appelli prefissati.
Contattateci via mail per concordare una data.

Materiale didattico e repository

- **Materiale**

- Dispense fornite dal docente
- Testi di riferimento (solo per approfondimenti)
 - Torralba, Isola, Freeman, "Foundations of Computer Vision", MIT press, 2024.
 - Zhang, Lipton, Li, Smola, Dive into Deep Learning, <https://d2l.ai>, 2020.
 - Elgendy, "Deep Learning for Vision Systems", Manning, 2020.
 - Forsyth e Ponce, Computer Vision a modern approach, Pearson, 2012.
 - Kaehler e Bradski, Learning OpenCV 3, O'Reilly, 2017.
 - Shi, "Emgu CV Essentials", Packt publishing, 2013.
 - Gonzalez e Woods, Elaborazioni delle immagini digitali, Prentice Hall, 3 edizione, 2008.

- **Repository:**

- <https://www.kaggle.com/>
- <https://public.roboflow.com/>
- <https://archive.ics.uci.edu/datasets>